# Clasificación de tumores cerebrales en cortes de MRI con una red neuronal convolucional compacta con control de fuga de datos

Miguel Muñoz, David Cardenas y Mario Celis

## I. Introducción

Los tumores del sistema nervioso central son un grupo heterogéneo cuyo tipo determina el pronóstico y el tratamiento [1]. La resonancia magnética (MRI) es la modalidad principal para detectarlos, pero su lectura es lenta y varía entre evaluadores. Por eso, un clasificador automático puede servir para priorizar estudios y como segunda opinión. Este trabajo aborda la clasificación de cortes 2D de MRI cerebral en cuatro clases: glioma, meningioma, tumor hipofisario (*pituitary*) y tejido sano.

Las CNN dominan la clasificación de imágenes desde que los kernels $3\times3$ apilados [2], la normalización por lotes [3] y las conexiones residuales [4] permitieron entrenar redes profundas de forma estable. Sobre el conjunto de figshare (3 064 cortes T1, tres tumores) [5], una CNN propia alcanza 96,56 % de *accuracy* [6]. Sin embargo, Yagis *et al.* [7] mostraron que dividir los datos de MRI a nivel de corte, y no de sujeto, puede inflar el *accuracy* de prueba hasta en 55 puntos porcentuales.

Los objetivos son: (i) construir un *pipeline* reproducible con una partición sin duplicados entre conjuntos; (ii) diseñar y entrenar una CNN basada en bloques de convolución y *max pooling*; y (iii) evaluarla con métricas clínicamente relevantes, cuantificar su variabilidad y el efecto de la fuga, e interpretarla con Grad-CAM [9]. Se propone una CNN de 0,29 M parámetros entrenada desde cero, que obtiene $97{,}1 \pm 0{,}6$ % de *accuracy* en prueba.

## II. Metodología

**Enfoque.** El *pipeline* (notebook adjunto) agrupa y particiona las imágenes, las preprocesa, entrena una CNN compacta desde cero, la evalúa y la interpreta con Grad-CAM.

**Datos.** Se usa el conjunto *Brain Tumor (MRI Scans)* de Kaggle: 7 023 imágenes (glioma 1 621, meningioma 1 645, *pituitary* 1 757, sano 2 000). Su tamaño y clases coinciden con la compilación de [10], que une figshare [5] y SARTAJ (tumores) con Br35H (clase sana). Las imágenes tienen 387 tamaños distintos (67,5 % de $512\times512$) y son, en la práctica, de un solo canal. Dos imágenes se agrupan si tienen el mismo MD5, o el mismo dHash y una correlación de Pearson $\geq$0,95 entre miniaturas; así, las 7 023 imágenes forman 5 835 grupos. La redundancia es muy desigual: el 52,2 % de las imágenes sanas son copias, frente a 0,2–7,3 % en los tumores.

**Partición y preprocesamiento.** La división 70/15/15 (5 016/1 004/1 003), estratificada por clase, se hace *por grupo*: ningún grupo ni duplicado exacto queda en dos particiones. Con una partición aleatoria, 220 imágenes de prueba (22 %) tendrían un casi-duplicado en entrenamiento.

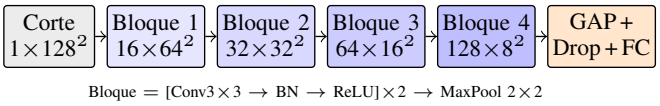



Fig. 1. Arquitectura de la CNN propuesta (294 228 parámetros). En cada bloque se indica el tamaño del mapa de salida.

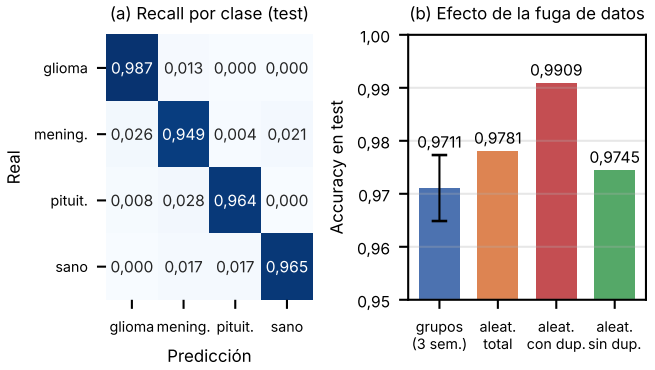



Fig. 2. (a) Matriz de confusión normalizada por fila (*recall*), semilla 42. (b) *Accuracy* en prueba: por grupos (media $\pm$ desv. est., 3 semillas) y aleatoria (completa y con/sin casi-duplicado en entrenamiento); el eje comienza en 0,95.

Aun así, 55 imágenes de prueba (5,5 %) comparten un dHash idéntico con una de entrenamiento: no son copias (correlación $<$0,95), sino cortes muy similares, probablemente del mismo paciente. Cada imagen se convierte a gris y se rellena con negro hasta hacerla cuadrada, sin deformar la anatomía. Luego se redimensiona a $128\times128$ y se normaliza con la media y desviación de entrenamiento (0,179/0,194). Solo en entrenamiento se aplica aumentación: volteo horizontal, rotación $\pm10°$, traslación 5 %, escala 0,9–1,1 y brillo/contraste $\pm15$ %.

**Arquitectura (Fig. 1).** La red tiene cuatro bloques estilo VGG [2], cada uno con [Conv $3\times3$–BatchNorm [3]–ReLU]$\times2$ y *max pooling* $2\times2$, con 16, 32, 64 y 128 filtros. Les siguen *global average pooling* [11], *dropout* 0,3 y una capa lineal de 4 salidas. El *global average pooling* reemplaza las capas densas para limitar los parámetros (294 228) frente a solo $\sim$5 000 imágenes de entrenamiento.

**Entrenamiento.** Se usa entropía cruzada con *label smoothing* 0,05 [12] y AdamW [13] (lr $10^{-3}$, *weight decay* $10^{-4}$, lote 64), con decaimiento coseno [14] durante 30 épocas como máximo. Se guarda el modelo con mayor F1-macro de validación (paciencia 8). Se usó PyTorch con semillas fijas (CPU; 43 min la corrida principal).

**Evaluación.** Se reportan *accuracy* con IC 95 % por *boot-*

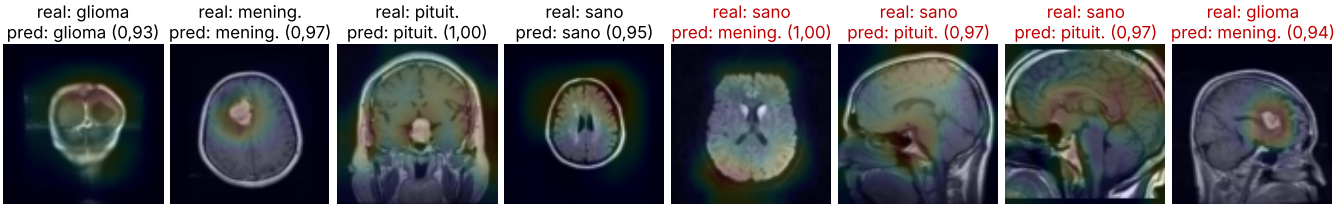



Fig. 3. Ejemplos de prueba con mapa Grad-CAM superpuesto (rojo: mayor contribución a la clase predicha). (a) Un acierto por clase. (b) Los cuatro errores de mayor confianza, de grupos de casi-duplicados distintos. Se indican la clase real, la predicha y la probabilidad.

TABLA I
RESULTADOS EN PRUEBA (1 003 IMÁGENES) DE LA CNN PROPUESTA.

| **Partición / semilla** | **Acc.** | **Acc. bal.** | **F1-macro** | **AUC** |
|---|---|---|---|---|
| Grupos, semilla 42 | 0,9661 | 0,9663 | 0,9657 | 0,9945 |
| Grupos, semilla 7 | 0,9691 | 0,9689 | 0,9685 | 0,9938 |
| Grupos, semilla 123 | 0,9781 | 0,9779 | 0,9778 | 0,9954 |
| **Grupos, media** $\pm$ **desv. est.** | **0,9711** $\pm$0,0062 | **0,9710** $\pm$0,0061 | **0,9707** $\pm$0,0063 | **0,9946** $\pm$0,0008 |
| Aleatoria (fuga), sem. 42* | 0,9781 | 0,9773 | 0,9772 | 0,9989 |

*Evaluada en su propia partición de prueba, no comparable 1:1 con las filas anteriores.

*strap* (1 000 remuestreos), *accuracy* balanceada, F1-macro (las clases están solo levemente desbalanceadas) y AUC uno-contra-todos. En el contexto clínico se analizan el *recall* por clase y los tumores clasificados como sanos. Se ejecutan dos experimentos con la misma configuración: E1 entrena con 3 semillas (42, 7, 123) para estimar media y desviación estándar; E2 entrena con la partición aleatoria y separa su prueba en imágenes con y sin casi-duplicado en entrenamiento. El *fine-tuning* de ResNet-18 [4] está implementado, pero no se ejecutó por falta de acceso a los pesos preentrenados.

## III. RESULTADOS

La Tabla I resume los resultados cuantitativos. Con la partición por grupos, la CNN logra $0{,}9711 \pm 0{,}0062$ de *accuracy* y $0{,}9946 \pm 0{,}0008$ de AUC. La semilla 42 obtiene 0,9661 (IC 95 %: 0,954–0,976). La brecha final entre entrenamiento y validación es de $\sim$1 punto (0,981 frente a 0,971). Por clase (Fig. 2a), el *recall* va de 0,949 en meningioma a 0,987 en glioma. Solo 5 de 717 tumores (0,7 %) se clasifican como sanos, y los cinco son meningiomas. En E2, la partición aleatoria eleva el *accuracy* a 0,9781. Dentro de esa prueba, las imágenes con casi-duplicado en entrenamiento alcanzan 0,9909 (2/220 errores), frente a 0,9745 (20/783) las que no lo tienen (Fig. 2b). Esta diferencia no es significativa con la prueba exacta de Fisher ($p = 0{,}19$). Con la partición por grupos, las 55 imágenes con dHash idéntico en entrenamiento se aciertan al 100 % en las tres semillas, frente a 0,9694 en el resto.

La Fig. 3 muestra los resultados cualitativos. En los aciertos de glioma, meningioma y *pituitary*, la activación se concentra sobre la lesión o la región selar. Los errores de mayor confianza son sobre todo cortes sanos atípicos: una imagen axial de difusión (DWI) predicha como meningioma con probabilidad $\approx$1,00 (5 copias en prueba) y cortes sagitales T1 predichos como *pituitary*. En ellos, el mapa no señala una lesión, sino estructuras de la línea media.

## IV. DISCUSIÓN

La CNN compacta generaliza bien: la pequeña brecha entre entrenamiento y validación indica un buen balance sesgo-varianza [15]. Contribuyen la regularización explícita (*weight decay*, *dropout*, *label smoothing* [12]) y el uso de *global average pooling* en lugar de capas densas [11]. La validación oscila con fuerza en las primeras $\sim$12 épocas y se estabiliza cuando el decaimiento coseno [14] reduce la tasa de aprendizaje. La desviación entre semillas (0,6 puntos) es comparable al IC de una sola corrida: diferencias menores a $\sim$1 punto entre configuraciones no son concluyentes sin repetición. El resultado está en el rango de [6] (96,56 %), aunque allí se usan 3 clases y validación a nivel de registro.

La clase más difícil es meningioma (*recall* 0,949, precisión 0,937). Se confunde con glioma cuando la lesión es heterogénea y con *pituitary* cuando está en la línea media, porque la localización, una señal que la red usa (Fig. 3a), deja de ser discriminativa. La fuga de datos actúa en la dirección descrita por [7]: los casi-duplicados se clasifican casi a la perfección. Aquí su magnitud es moderada (+0,7 puntos), porque solo el 22 % de la prueba está contaminado y el conjunto contiene cortes seleccionados y no volúmenes completos.

La principal limitación es un posible atajo [8]: la clase sana proviene de otra fuente (Br35H [10]): su resolución mediana es $232 \times 243$ px frente a $512 \times 512$ en los tumores, su intensidad media es mayor (60 frente a 33–49) y el 69 % no es cuadrada, por lo que el relleno le añade bordes negros que las demás clases casi no tienen. Los errores sobre cortes sanos atípicos (Fig. 3b) sugieren que parte de la separación sano/tumor depende de la secuencia y no de la patología. Además, sin identificador de paciente persiste una fuga residual: el 5,5 % de la prueba se acierta sin error, lo que infla el *accuracy* en $\sim$0,2 puntos (0,9711 frente a 0,9694). A esto se suman la resolución reducida (128 px) y la falta de un modelo preentrenado para comparar. Como mejoras se proponen: (i) ejecutar el *fine-tuning* de ResNet-18 [4]; (ii) normalizar intensidades por imagen y evaluar estratificando por secuencia o en un conjunto externo; (iii) mayor resolución, para separar mejor meningioma y glioma; y (iv) calibrar las probabilidades y fijar un umbral que minimice los falsos negativos tumor$\rightarrow$sano.

## REFERENCIAS


[1] D. N. Louis *et al.*, "The 2021 WHO classification of tumors of the central nervous system: A summary," *Neuro-Oncology*, vol. 23, no. 8, pp. 1231–1251, 2021, doi: 10.1093/neuonc/noab106.

[2] K. Simonyan and A. Zisserman, "Very deep convolutional networks for large-scale image recognition," in *Proc. Int. Conf. Learn. Represent. (ICLR)*, 2015, arXiv:1409.1556.

[3] S. Ioffe and C. Szegedy, "Batch normalization: Accelerating deep network training by reducing internal covariate shift," in *Proc. Int. Conf. Mach. Learn. (ICML)*, 2015, pp. 448–456.

[4] K. He, X. Zhang, S. Ren, and J. Sun, "Deep residual learning for image recognition," in *Proc. IEEE Conf. Comput. Vis. Pattern Recognit. (CVPR)*, 2016, pp. 770–778.

[5] J. Cheng *et al.*, "Enhanced performance of brain tumor classification via tumor region augmentation and partition," *PLoS ONE*, vol. 10, no. 10, Art. no. e0140381, 2015, doi: 10.1371/journal.pone.0140381.

[6] M. M. Badža and M. Č. Barjaktarović, "Classification of brain tumors from MRI images using a convolutional neural network," *Appl. Sci.*, vol. 10, no. 6, Art. no. 1999, 2020, doi: 10.3390/app10061999.

[7] E. Yagis *et al.*, "Effect of data leakage in brain MRI classification using 2D convolutional neural networks," *Sci. Rep.*, vol. 11, 2021, doi: 10.1038/s41598-021-01681-w.

[8] R. Geirhos *et al.*, "Shortcut learning in deep neural networks," *Nat. Mach. Intell.*, vol. 2, no. 11, pp. 665–673, 2020, doi: 10.1038/s42256-020-00257-z.

[9] R. R. Selvaraju, M. Cogswell, A. Das, R. Vedantam, D. Parikh, and D. Batra, "Grad-CAM: Visual explanations from deep networks via gradient-based localization," in *Proc. IEEE Int. Conf. Comput. Vis. (ICCV)*, 2017, pp. 618–626.

[10] J. Chaki, "Brain tumor MRI dataset," IEEE DataPort, doi: 10.21227/1jny-g144; versión de Kaggle "Brain Tumor (MRI Scans)" (rm1000). [En línea]. Disponible: https://www.kaggle.com/datasets/rm1000/brain-tumor-mri-scans

[11] M. Lin, Q. Chen, and S. Yan, "Network in network," in *Proc. Int. Conf. Learn. Represent. (ICLR)*, 2014, arXiv:1312.4400.

[12] C. Szegedy, V. Vanhoucke, S. Ioffe, J. Shlens, and Z. Wojna, "Rethinking the inception architecture for computer vision," in *Proc. IEEE Conf. Comput. Vis. Pattern Recognit. (CVPR)*, 2016, pp. 2818–2826.

[13] I. Loshchilov and F. Hutter, "Decoupled weight decay regularization," in *Proc. Int. Conf. Learn. Represent. (ICLR)*, 2019, arXiv:1711.05101.

[14] I. Loshchilov and F. Hutter, "SGDR: Stochastic gradient descent with warm restarts," in *Proc. Int. Conf. Learn. Represent. (ICLR)*, 2017, arXiv:1608.03983.

[15] I. Goodfellow, Y. Bengio, and A. Courville, *Deep Learning*. Cambridge, MA, USA: MIT Press, 2016.